

JEAN FLOW — Resumen técnico del sistema

Captura y certificación de datos de mercado de criptomonedas · Documento para revisión académica · Agosto 2026

1. Objetivo

Construir una plataforma que capture en tiempo real el libro de órdenes y las transacciones del par BTC/USDT en Binance (mercados spot y futuros), con garantías verificables de integridad, como base para entrenar modelos predictivos y, en fases posteriores, operar de forma automatizada con gestión de riesgo.

2. Arquitectura

- **Colector** (Python 3.12 / asyncio): dos conexiones websocket concurrentes (spot y futuros), reconstrucción del libro de órdenes con journal causal y re-sincronización en caliente (hot-rebase) sin interrumpir la grabación.
- **Persistencia**: CSV inmutable con escritura atómica (archivo temporal + fsync + renombre), rotación por segmentos y compromiso criptográfico SHA-256 por archivo; conversión posterior a Parquet+ZSTD (reducción medida del 98,1–98,6%) con verificación fila a fila.
- **Supervisión**: proceso supervisor con heartbeat, deadline monótonico independiente del heartbeat y archivos de estado (session/READY/STOP) para certificar cada corrida.
- **Infraestructura**: máquina virtual Linux (Ubuntu 24.04, 8 vCPU, 32 GB) en Google Cloud, servicios systemd, operación remota auditada.
- **Desarrollo asistido por IA con revisión cruzada**: un modelo generativo escribe los cambios bajo un contrato estricto (archivos autorizados, prohibiciones explícitas, claves de idempotencia); un segundo agente revisa diffs, verifica hashes y ejecuta la suite de pruebas; nada se acepta sin 100% de pruebas y verificación de alcance; toda decisión queda documentada en una memoria compartida.

3. Garantías de integridad (auditorías automáticas)

- **Journal/replay causal**: cada delta aplicado al libro se registra y la reconstrucción se reproduce de forma determinista; el replay debe coincidir con el estado final.
- **Identidad**: secuencias de ingesta completas (ej.: 1→93.717 sin faltantes, cero conflictos, cero duplicados divergentes).
- **Métricas de rendimiento** con umbrales p99 (aplicación al libro, parseo, pipeline, retraso del event-loop ≤ 20 ms).
- **Cero archivos parciales** al cierre y verificación SHA-256 contra el compromiso de captura.

4. Resultados certificados (mediciones reales)

Prueba / métrica	Resultado
Gate de 30 min de captura continua	1.800,06 s saludables, RC 0, 3,25 M filas (1,26 GB), auditorías 4/4 PASS, suite 9/9
Gate de 2 horas	Ejecutado el 27/08/2026 (en certificación al cierre de este documento)
Latencia interna del pipeline (p99)	parseo 0,19–0,36 ms · libro 1,2–2,7 ms · pipeline 1,9–3,3 ms
Latencia de entrega exchange→sistema	p50 37,9 ms · p99 46,4 ms (n=19.553 eventos; piso físico 37,5 ms por distancia geográfica)
Compresión CSV→Parquet	98,15–98,64% con equivalencia verificada por hash y digest lógico

5. Metodología de certificación por gates

La resistencia del sistema se certifica por etapas de duración creciente (30 min → 45 min → 2 h → 6 h → 24 h → 7 días). Cada gate se acepta únicamente con: ventana saludable completa sin reinicios, código de salida 0, cero archivos parciales, auditorías de integridad en PASS y suite de pruebas al 100%. Un defecto histórico de corte a los ~10 minutos fue diagnosticado (deadline fijo no revalidado tras re-sincronización y condición de carrera en el heartbeat) y corregido con evidencia reproducible.

6. Plan de fases

Fase 1 — Grabación continua (fábrica de datos, no se detiene). **Fase 2** — Entrenamiento de modelos de series temporales (baseline con gradient boosting antes que redes profundas; ventana deslizante de re-entrenamiento). **Fase 3** — Simulación obligatoria: backtesting contra los datos certificados (replay causal propio) y paper trading en el entorno de pruebas oficial del exchange, descontando comisiones y deslizamiento. **Fase 4** — Ejecución real con capital reducido, límites de pérdida y parada de emergencia. Bucle permanente: grabar → re-entrenar → re-simular → operar.

7. Trabajo en curso y preguntas abiertas

Migración planificada de la captura a la región de Tokio (donde reside el motor de emparejamiento del exchange) para reducir la latencia de entrega de ~38 ms a un objetivo de 5–8 ms; activación del worker Parquet desatendido antes de las corridas de 7 días (presupuesto de disco medido: ~54 GB/día de CSV crudo); extensión del colector a múltiples símbolos. Las preguntas metodológicas específicas se plantean en el correo adjunto.

Documento de resumen sin información sensible: no incluye código fuente, credenciales, direcciones de infraestructura ni identificadores de sesión. Elaborado con asistencia de IA bajo el flujo de revisión descrito en la sección 2.